

中原大學

資訊工程學系

109 學年度專題實驗期末報告

應用深度學習技術之胸腔 X 光 病徵辨識輔助系統

組員

資訊四甲 10627122 陳俐欣

資訊四甲 10627146 陳浩瑋

資訊四乙 10627237 陳泓宇

指導老師：朱守禮老師

109/12/04

目錄

1. 摘要.....	4
2. 研究動機.....	4
3. 研究問題與研究方法.....	5
4. 專題運行結果.....	6
5. 結論.....	30
6. 未來發展.....	30
7. 參考文獻.....	30

圖 1、14 種病徵辨識模型.....	6
圖 2、ChestX-ray14 資料集	7
圖 3、程式執行結果 (Epoch=100)	8
圖 4、各模型在 Epoch=100, Batch size 為 36 及 44 下對肺炎的精準度	9
圖 5、14 類病徵辨識模型之預測結果輸出.....	9
圖 6、COVID-19 辨識模型.....	13
圖 7、資料增強範例.....	13
圖 8、固定之實驗 augementer 結構.....	15
圖 9、各種圖片強化方式下的模型精準度.....	15
圖 10、最佳權重之 Testing 結果輸出	16
圖 11、最佳權重之圖片增強方法組合.....	16
圖 12、重新訓練 COVID-19 模型之測試結果	18
圖 13、COVID-19 模型測試 ChestX-ray14 之精準度	18
圖 14、COVID-19 模型之第一部分結果輸出.....	26
圖 15、14 類病徵辨識模型針對非 Covid-19 之圖片辨識結果	27
圖 16、綜合結果輸出.....	27
圖 17、所使用嵌入式平台 Jetson Nano	28
圖 18、Jetson Nano 載入 COVID-19 模型之辨識結果.....	28
圖 19、Jetson Nano 實際運行 COVID-19 模型	29
圖 20、個人電腦實際運型 COVID-19 模型.....	29
表 1、14 類病徵辨識模型各病徵資料比例.....	7
表 2、各架構對模型訓練精準.....	8
表 3、8 種病徵之辨識結果熱像圖.....	10
表 4、COVID-19 模型資料比例.....	13
表 5、資料集擴充所選用的圖片增強方法列表.....	14
表 6、所選用的圖片增強的順序及條件.....	14
表 7、各個 augmentation techniques 對於 transfer learning 辨識準確度	15
表 8、部分正確標籤範例(綠色框線)以及部分錯誤標籤範例(紅色標籤).....	17
表 9、COVID-19 模型重新訓練之參數結果比較.....	18
表 10、Add()圖像增強函數對於 COVID-19 模型預測之效果	19
表 11、Multiply()圖像增強函數對於 COVID-19 模型預測之效果	20
表 12、Sharpen()圖像增強函數對於 COVID-19 模型預測之效果.....	20
表 13、GammaContrast()對於 COVID-19 模型預測之效果(固定第一個參數)....	20
表 14、GammaContrast()對於 COVID-19 模型預測之效果(固定第二個參數)....	20
表 15、GaussianBlur ()對於 COVID-19 模型預測之效果(固定第一個參數)	21
表 16、GaussianBlur ()對於 COVID-19 模型預測之效果(固定第二個參數)	21
表 17、A. GaussianBlur(sigma=(1.0)).....	21

表 18、B. GaussianBlur(sigma=(2.5))	22
表 19、C. GammaContrast((0.7))	22
表 20、D. GammaContrast((1.3))	22
表 21、E. Sharpen(alpha=(0.03), lightness=(0.5)).....	23
表 22、F. Sharpen(alpha=(0.03), lightness=(1.1))	23
表 23、兩種圖像增強方法疊加之結果比較.....	23
表 24、G. 高斯模糊+Gamma 對比.....	24
表 25、H. 銳利化+高斯模糊	24
表 26、I. Gamma 對比+銳利化	24
表 27、三種圖像增強方法疊加結果比較.....	25
表 28、J. Gamma 對比+高斯模糊+銳利化.....	25
表 29、十回合辨識演算法所使用的方法.....	26
表 30、Jetson Nano 和個人電腦之比較.....	29

1. 摘要

隨著時代的演進，人們開始更加注重自身的身體健康。現在已有許多國家著手研究如何將深度學習應用在醫療診斷、利用深度學習模型預先辨識病徵種類，將結果提供給醫生作為參考，提高就醫的效率，加速診斷病患所需要的時間、提早給予適當治療；而我們計劃使用深度學習模型在 X 光進行初步病徵辨識、針對肺炎的加強診斷、及未來潛在的病徵預測。

本計劃的目標，第一階段是實作兩個用來辨識的深度學習模型，包含 X 光圖的初步辨識、及針對新冠肺炎的診斷辨識之模型，待第一階段的模型達到期望之精確度後，我們將進入第二階段，藉由初步辨識之模型多回合結構演算法，希望提高新冠肺炎辨識之準確度，第三階段會嘗試把此 X 光圖判讀系統移植在嵌入式裝置上，讓一切的診斷可以以更機動性的方式執行，接近病患的所在處。將上述三階段的結果整合，方便給予醫生判讀上的建議或參考，以減少病患在等待報告的時間，提高就醫時的品質與效率。

2. 研究動機

於 2020 年 1 月 30 日時，世界衛生組織宣布由新型冠狀病毒所引發的嚴重特殊傳染性肺炎為公共衛生緊急事件，因此疾病證明可經由人傳人的方式感染，並迅速的在各國間擴散傳播，導致確診的病例數逐日呈指數增加演變成全球大流行的疫情。即時發現疑似感染 COVID-19 的人並在傳染期前進行下一步的隔離與檢查變得格外重要。感染 COVID-19 的主要跡象包含發燒、咳嗽等常見的症狀，並非外表上就能明顯判別，因此常會需要使用照射胸腔 X 光圖的方式進一步確認體內的變化，而在進行 X 光圖檢測的過程中通常需要較長的一段等待時間，因此本研究文章希望能藉由深度學習來協助放射師需要長時間診斷 X 光圖的過程。

本計畫中我們設計一深度學習的模型，使其能夠有自主判斷分析 X 光的功能，協助專業醫師初步分析，如：從 X 光中找到病徵的特徵，並盡可能地將所有的病徵都找出來，減輕醫師的工作負擔，再來，我們期望此框架能夠針對較不明顯的病徵特徵作紀錄，並留意此位置在未來是否有發展成疾病的機會，預測短時間後病人可能潛在的病徵，讓醫師能夠透過短時間預測的結果來為病人建議是否安排更詳細的檢查，預防疾病快速演化導致花費更龐大的醫療資源的情況發生。

上述是我們第一階段深度學習框架主要負責執行的工作內容。我們期望將我們的模型也能夠順利的在嵌入式系統上運行，以期提高專業醫師使用診斷模

型的方便性，讓醫師能夠更便利快速的藉由機器幫助診斷，減少對專業醫師造成的負擔、受測者等待結果報告產出的時間，提高受測者快速就診避開疾病的機會，將耗費的人力及醫療資源降低，更有效率的使用醫療技術。

3. 研究問題與研究方法

(1) 判斷 X 光中有哪些 14 類胸腔病徵與病灶。

步驟一、訓練

整理出已經經過放射師手動標註的 14 類胸腔 X 光，利用這些確認過的圖片當作預訓練之深度模型的輸入，藉由更換不同模型、超參數、以及分類層結構，觀察輸出結果的精準度，再進行相關參數的微調，為了提高另一模型之準確度，所以我們以其中肺炎精準度為第一優先考量。

步驟二、辨識

將欲辨識的胸腔 X 光放入以訓練好之深度學習模型，得出的結果即是模型透過圖像辨識判斷出可能性病徵。

(2) 對新冠肺炎相關疾病做進一步判斷。

步驟一、資料集前處理

訓練一個用來診斷新冠肺炎疾病的模型，需要讓該模型能對於該疾病的樣態，以及對於辨識疾病在身體的位置能夠有足夠的辨識度，為此我們先將 Kaggle 上取得的照片，進行整理及篩選，將過於模糊不清之胸腔 X 光剔除，以免影響模型訓練時的模糊不清。

步驟二、資料擴增

我們藉由 Data Augmentation，嘗試多樣組合，以增加資料及之豐富度。

步驟三、模型訓練

由於目前公開之新冠肺炎胸腔 X 光並不多，我們希望藉由遷移學習來提高便是精準度，因此我們藉由上一個 14 類胸腔病徵模型之卷積層，作為本階段之遷移學習初始權重，進行遷移訓練。

(3) 多回合辨識演算法。

步驟一、尋找適合的 augmentation

測試單一 augmentation 函數，對於模型辨識的辨識能力，作為步驟二之組合參考數據。

步驟二、設計、測試多回合 augmentation 組合

為提高新冠肺炎辨識之精準度，因此希望藉由增加 augmentation，提高 X 光片亮度、銳利度等，來模擬放射師對於 X 光片不同角度、方式的檢測行為。

(4) 將深度學習的架構移植至嵌入式系統。

，在上述相關的深度模型建立完成後，將此系統移植至可移動的嵌入式裝置上，結合目前現有的移動式 X 光機（主要的功能為前往病房，為不便移動的病患拍攝 X 光），在為病患照攝 X 圖時能在當下做即時的診斷建議。

4. 專題運行結果

● X 光 14 類病徵辨識模型

我們在參考 CheXNet 的論文中，發現已經有研究團隊時做出可以藉由一張胸腔 X 光圖辨識病徵的模型，找出可能為 14 種疾病中的哪一類，或是該受測者為健康狀態。此篇論文是使用 ChestX-ray14 資料集作為訓練，其資料集為許多進行相關研究的團隊所使用，因此我們也將由此 CheXNet 模型，及此 ChestX-ray14 資料集作為起始。

ChestX-ray14 資料集的產生目的為有效率的保存 X 光影像訊息並建立大型的數據倉庫，使研究者能利用 X 光的數據庫來進行深度學習相關研究，建立大規模高精準度的電腦輔助診斷系統，減少醫師判讀 X 光的負擔。




圖 1、14 種病徵辨識模型

圖 1 為我們在實現 14 類病徵辨識模型的主要架構，嘗試各種模型對於病癥辨識效果，重新訓練將模型的最後一層全連階層選用為我們所需的分類數，因此可看到在模型的最後一層 Output 為 14 個輸出值。

圖 2 為我們在訓練 14 類病徵辨識模型所使用的資料集 ChestX-ray14，為 ChestX-ray8 的擴充，總共包含 112,120 張正面胸腔 X 光圖，並有 30,805 位不同的病人，以及 14 類病徵的標籤(Atelectasis, Cardiomegaly, Effusion, Infiltration, Mass, Nodule, Pneumonia, Pneumothorax, Consolidation, Edema, Emphysema, Fibrosis, Pleural_Thickening, Hernia)，而每一張胸腔 X 光圖可能包含 2 個病徵以上的標籤。




圖 2、ChestX-ray14 資料集

表 1 為在訓練 14 種病徵分類模型時，每一種病徵分別在 Train、Val、Test 的比例(其中可能一張 X 光圖中包含 2 種以上的病徵)，而因為此模型要辨識的種類有 14 種，在訓練時需要較大量的資料，Train、Val、Test 的比例約為 93:6:1。從表格中可看出在 ChestX-ray14 的資料集中，Infiltration 所佔的比例較高，Hernia 的比例最低，而我們主要觀察的 Pneumonia 為次低。

表 1、14 類病徵辨識模型各病徵資料比例

Pathology	Train	Val	Test
Atelectasis	10768(14.2%)	652(14.2%)	139(12.0%)
Cardiomegaly	2564 (3.4%)	155 (3.4%)	58 (5.0%)
Effusion	12381(16.4%)	737(16.1%)	200(17.2%)
Infiltration	18428(24.4%)	1156(25.2%)	311(26.8%)
Mass	5351 (7.1%)	358 (7.8%)	74 (6.4%)
Nodule	5896 (7.8%)	344 (7.5%)	92 (7.9%)
Pneumonia	1329 (1.8%)	79 (1.7%)	25 (2.1%)
Pneumothorax	4987 (6.6%)	268 (5.9%)	48 (4.1%)
Consolidation	4296 (5.7%)	295 (6.4%)	77 (6.6%)

Edema	2138 (2.8%)	136 (3.0%)	30 (2.6%)
Emphysema	2380 (3.2%)	115 (2.5%)	22 (1.9%)
Fibrosis	1572 (2.1%)	87 (1.9%)	28 (2.4%)
Pleural_Thickening	3149 (4.2%)	184 (4.0%)	53 (4.6%)
Hernia	209 (0.3%)	15 (0.3%)	4 (0.3%)
Total	75448(92.9%)	4581(5.6%)	1161(1.4%)

```

Epoch 00100: val_loss did not improve from 0.14949
*****
current learning rate: 9.9999993922529e-09
*** epoch#100 dev auoc ***
1. Atelectasis: 0.8120576054623246
2. Cardiomegaly: 0.8885961661908762
3. Effusion: 0.8770101658490577
4. Infiltration: 0.7126609864931664
5. Mass: 0.8461285420844772
6. Nodule: 0.7661305189865558
7. Pneumonia: 0.7918361814514578
8. Pneumothorax: 0.8677350106750362
9. Consolidation: 0.7826036210190814
10. Edema: 0.8777271110056927
11. Emphysema: 0.9318423572332142
12. Fibrosis: 0.7606504397025363
13. Pleural_Thickening: 0.7784416167241477
14. Hernia: 0.826920845857723
*****

```

圖 3、程式執行結果 (Epoch=100)

目前我們藉由參考程式碼進行不同模型的測試，包含 (DenseNet121 、 VGG16 、 VGG19 、 ResNet50 、 InceptionV3 、 InceptionResNetV2 、 NASNetMobile)，藉由調整 batch size 的大小，在不同的 CNN 模型下發現 DenseNet121 是對於肺炎的辨識精確度相對高的模型。同時，在修改 epoch 時發現，在 epoch=100 和 epoch=10 的情況下，雖然 accuracy 和 loss 值皆有收斂，但兩者的精確度並無太大差距，而 epoch=100 所耗費的時間長達三天，其提升的精準度並不如預期。

表 2、各架構對模型訓練精準

各 CNN 模型對肺炎辨識準確度	Batch size 36	Batch size 44
VGG16	0.5	0.5
VGG19	0.5	0.5
DenseNet121	0.751201	0.791263
ResNet50	0.774085	0.733327
InceptionV3	0.775995	0.768409
InceptionResNetV2	0.781870	0.782936




圖 4、各模型在 Epoch=100, Batch size 為 36 及 44 下對肺炎的精準度

由圖 4 中得知，VGG16、VGG19 對於高複雜圖片的分類能力並不良好，準確度僅有 50%，而其餘 CNN 模型分類能力皆有 70%以上、甚至有高達近 80%的準確度；我們最後選擇 DenseNet121 做為我們第一部分之主要辨識模型。

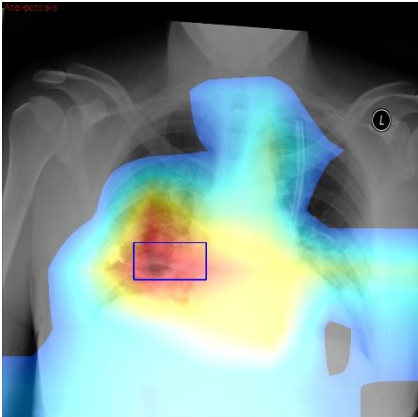
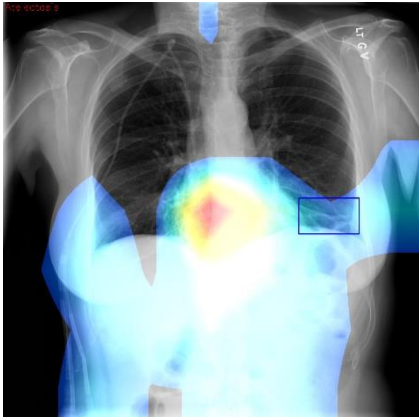
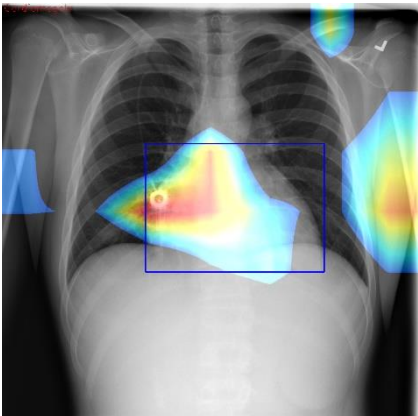
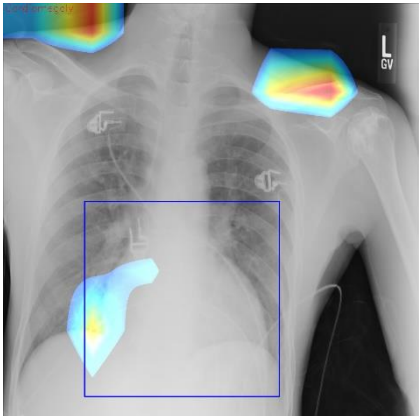

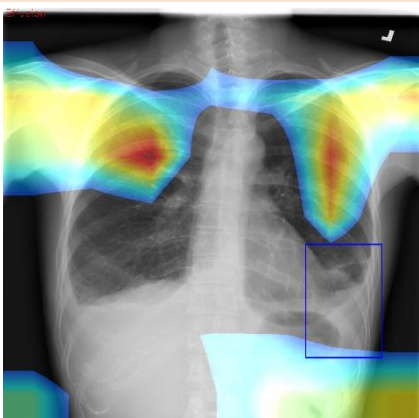
圖 5 為 14 類病徵辨識模型針對測試照片所預測的潛在病徵，針對一張圖，將模型所認為有可能存在的病徵列出，並寫出至試算表中，方便尋找特定照片的預測結果。

Image Index	Predict label
00002022_005.png	
00002437_032.png	Infiltration Nodule Pneumonia Consolidation Edema
00002720_011.png	
00003062_002.png	Infiltration Pneumonia Consolidation Edema
00003669_005.png	Cardiomegaly
00004470_006.png	Infiltration Pneumonia Consolidation
00004547_014.png	Atelectasis Effusion Infiltration Mass
00004858_043.png	
00004991_004.png	Cardiomegaly Nodule
00005442_005.png	Cardiomegaly
00005538_001.png	Infiltration

圖 5、14 類病徵辨識模型之預測結果輸出

為方便觀察我們所訓練出的 14 類病徵辨識模型辨識的結果，我們將預測出的結果用熱像圖的方式呈現，並對照原始資料集中所給的真值做比對，藍色框線為真值。表 3 為擷取 8 種病徵的辨識結果並以熱力圖的方式呈現病並與真值比較。



表 3、8 種病徵之辨識結果熱像圖

Atelectasis	
辨識較好結果	辨識較差結果
	
Cardiomegaly	
辨識較好結果	辨識較差結果
	
Effusion	
辨識較好結果	辨識較差結果
	

Infiltration

辨識較好結果



辨識較差結果



Mass

辨識較好結果


辨識較差結果




Nodule

辨識較好結果

辨識較差結果





- Covid-19 的辨識模型：

第二部分之 COVID-19 病徵分類，因為與第一部分(14 類病徵辨識模型)兩者輸入資料為有強烈的相似性，皆為胸腔 X 光片之正視圖，然而 COVID-19 的確診 X 光圖資料集數量並不多，因此我們藉由訓練好的 14 類分類模型權重、更換分類層，進行轉移學習，利用 14 類病徵辨識模型的卷積層來提取 COVID-19 之 X 光圖的特徵，嘗試獲得較好的分類準確度。由圖 5 可看到 COVID-19 辨識模型的主要架構與第一部份的 14 類病徵辨識模型的架構相符，差別在於最後的分類層，在此辨識 COVID-19 的模型僅需要「是」和「否」兩類。




圖 6、COVID-19 辨識模型

(1) 收集資料集、資料集資料增強，使資料多樣化

由於目前公開可使用的 COVID-19 X 光圖資料集較少，我們僅在網路上收集到 2,042 張，表 3 為訓練 COVID-19 辨識模型時所採用的資料比例，Train、Val、Test 的比例取 3:1:1，而 COVID-19 的資料數量相較於十四類病徵分類的資料集較為不足，擔心對於轉移學習上會產生過擬合的現象，因此我們藉由 python 所提供「imgaug」函式庫進行資料增強的處理，產生更多可用於訓練的資料。表 4 為我們在進行資料增強處理時所參考使用的方法，透過個別增強方法的使用並重新作模型訓練，紀錄每一種增強方法對於模型精準度的影響，找到未來較適合用於訓練模型的方法與使用程度。

表 4、COVID-19 模型資料比例

	Train	Val	Test
COVID-19	291 (23.8%)	97(23.8%)	97(23.9%)
Normal	933 (76.2%)	311(76.2%)	309(76.1%)
Total	1224(60%)	408(20%)	406(20%)

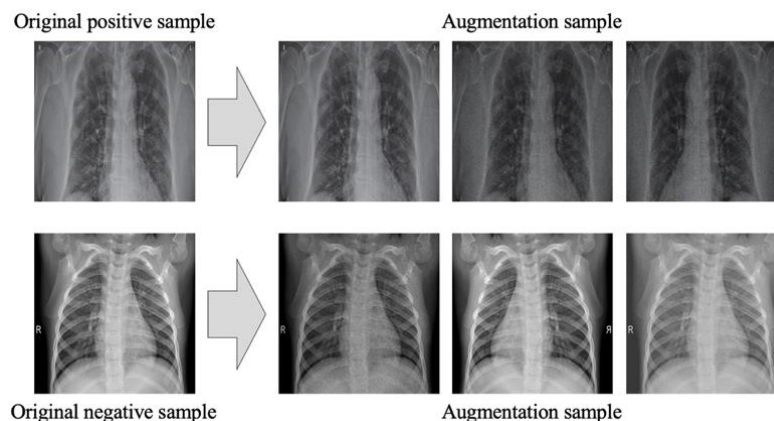


圖 7、資料增強範例

表 5、資料集擴充所選用的圖片增強方法列表

圖片增強方法	範圍	方法說明
Fliplr	0.5	50%機率圖片會水平翻轉
Add	[-20, +20]	在圖片上每一個 pixel 加上一個介於 -20~20 的值
AdditiveGaussianNoise	[0, 0.03*255]	以 pixel 為單位向影像新增高斯白雜訊
AdditiveLaplaceNoise	[0, 0.03*255]	以 pixel 為單位向影像新增拉普拉斯雜訊
Multiply	[0.5, 1.5]	給影像中的每個 pixel 乘一個介於 0.5~1.5 相同值，使得圖片更亮或者更暗。
MultiplyElementwise	[0.5, 1.5]	給影像中的每個 pixel 乘一個介於 0.5~1.5 隨機值，使得每一 pixel 更亮或者更暗。
SaltAndPepper	0.05	移除 5%的 pixel 換成黑或白。

表 6、所選用的圖片增強的順序及條件

選用圖片增強的順序及條件	方法說明
Sequential, random_order = True	列出的 Augmenter list 以隨機順序增加至圖片上
SomeOf, random_order = True	從列出的 Augmenter list 中，挑出指定數量或隨機數量，以隨機順序增加至圖片上
OneOf	從列出的 Augmenter list 中，挑選一個增加至圖片上

為避免模型訓練時是以記憶資料集順序的方式，我們除了使用資料增強(對比、明暗、高斯雜訊等)的方法來增加資料集，同時使用隨機選擇資料增強的方式，讓每張新增的資料不是按照一貫的規則。

(2) 嘗試多樣的訓練數據增強對於辨識能力的提升

A. 嘗試個各個數據資料增強方法，對於在資料集數量不足的轉移學習下的影響及表現。每次實驗的訓練 Epoch 均為 15、Batch size 為 16、Steps 為 115、卷積層權重值皆相同(第一部分 14 類病徵辨識模型時的最佳權重)、均含有 Fliplr (0.5)，且選用圖片增強的順序條件均相同。

```

augmenter = iaa.SomeOf((0,None),
    [
        iaa.Fliplr(0.5),
        iaa.Add((-20, 20))
    ],
    random_order=True,

```

圖 8、固定之實驗 augmenter 結構

表 7、各個 augmentation techniques 對於 transfer learning 辨識準確度

圖片增強方法	範圍	Normal accuracy	COVID-19 accuracy	Mean accuracy
Add	0.5	0.99375	0.99375	0.99375
AdditiveGaussianNoise	[-20, +20]	1.0	1.0	1.0
AdditiveLaplaceNoise	[0, 0.03*255]	0.98125	0.98125	0.98125
Multiply	[0, 0.03*255]	1.0	1.0	1.0
MultiplyElementwise	[0.5, 1.5]	1.0	1.0	1.0
SaltAndPepper	[0.5, 1.5]	0.9	0.8875	0.89375

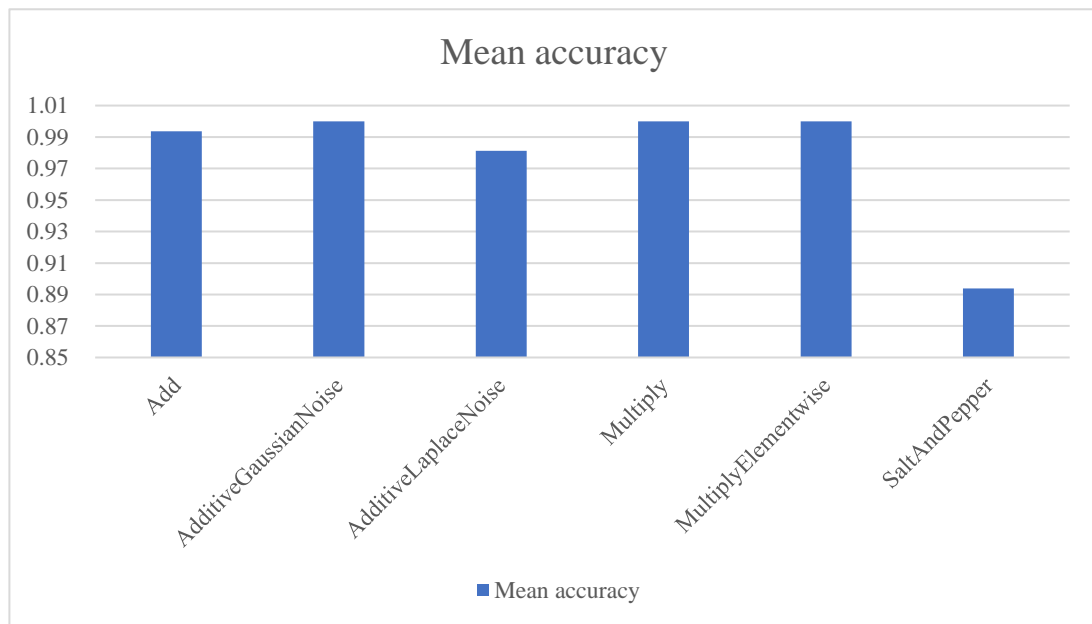


圖 9、各種圖片強化方式下的模型精準度

從表 7 中可觀察到，大部分 augmentation techniques 對於 COVID-19 的辨識可以達到 99% 準確率以上，但 SaltAndPepper(0.05) 對於辨識上可能會產生過多的破壞，使準確率下降至僅有 90%，因此在接下來實驗中，我們會較少選用 SaltAndPepper。

B. 嘗試多種不一樣的資料增強方法「組合」，觀察對於 COVID-19 的辨識分類準確率的影響，每次模型訓練時的實驗 Epoch 均為 150、Batch size 為 16、Steps 為 115 且卷積層權重值皆相同(第一部分 14 類病徵辨識模型時的最佳權重)。經過多次適當調整下，選用不同的資料增強方法組合，得到目前測試的最高平均準確率高達 0.9875，而我們選用的方法組合與序列如圖 11。

```
Normal: 0.9875
Covid_19: 0.9874999999999999
-----
mean auroc: 0.9875
```


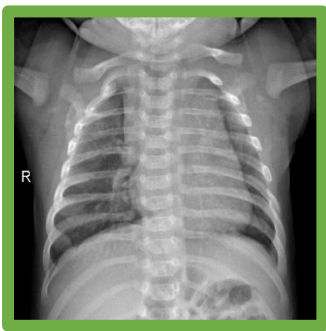
圖 10、最佳權重之 Testing 結果輸出

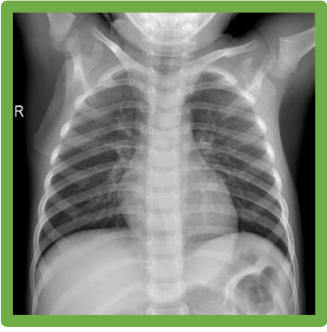
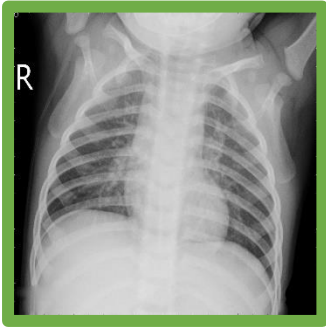
目前實驗得到最高的圖片增強組合如圖 11，為從不添加增強、50%左右翻轉、對每個 pixel 增加數值、增加高斯白雜訊、增加拉普拉斯雜訊及調整圖片亮暗裡挑選一至三種且對相同 batch 中每一張照片添加次序不同，其中增加高斯白雜訊、增加拉普拉斯雜訊及調整圖片亮暗為從三種或兩種中挑選一種進行增強，使對圖片有樣的增強方式。

```
augmenter = iaa.SomeOf((1,3),
[
    iaa.Noop(),
    iaa.Fliplr(0.5),
    iaa.Add((-15, 15)),
    iaa.OneOf([
        iaa.AdditiveGaussianNoise(scale=(0, 0.01*255)),
        iaa.AdditiveGaussianNoise(scale=(0, 0.03*255)),
        iaa.AdditiveGaussianNoise(scale=(0, 0.05*255))
    ]),
    iaa.OneOf([
        iaa.AdditiveLaplaceNoise(scale=(0, 0.01*255)),
        iaa.AdditiveLaplaceNoise(scale=(0, 0.03*255)),
        iaa.AdditiveLaplaceNoise(scale=(0, 0.05*255))
    ]),
    iaa.OneOf([
        iaa.Multiply((0.5, 1.0)),
        iaa.MultiplyElementwise((0.5, 1.0))
    ])
],
random_order=True,
)
```

圖 11、最佳權重之圖片增強方法組合

表 8、部分正確標籤範例(綠色框線)以及部分錯誤標籤範例(紅色標籤)

					
Rank	Predicted Class	Certainty	Rank	Predicted Class	Certainty
1	Covid_19	79.51%	1	Normal	95.77%
2	Normal	22.26%	2	Covid_19	4.18%

					
Rank	Predicted Class	Certainty	Rank	Predicted Class	Certainty
1	Normal	88.04%	1	Normal	88.23%
2	Covid_19	11.09%	2	Covid_19	12.21%

(3) Transfer learning 及 Retrain learning 比較

為了驗證在訓練 COVID-19 辨識模型時使用轉移學習相較於重新訓練是否真的對於我們有較好的表現，我們以相同的資料集、相同的資料增強方式、相同的 Hyperparameters，但不選擇使用 14 類分類模型權重，重新進行訓練，從圖 12 可看到利用重新訓練的方式(不調用 14 類病徵辨識模型的權重)建立 COVID-19 辨識模型的 Testing 結果平均準確率僅有 0.55，得知對於本階段實驗因為 COVID-19 資料集取得不易、數量較稀少，藉由相似輸入之轉移學習可得較好準確率。

```

Normal: 0.565625
Covid_19: 0.53125
-----
mean auroc: 0.5484375

```

圖 12、重新訓練 COVID-19 模型之測試結果

(4) 加入 ChestX-ray14 資料及進行測試並修正模型

為提升 COVID-19 模型再辨識不同資料集來源圖片的可靠度，我們將 ChestX-ray14 資料集中的照片與 Covid-19 資料集混合，分成 covid 與 not-covid 兩類，依照時間序列來看，ChestX-ray14 資料集初被建立時，Covid-19 尚未被發現，因此我們將 ChestX-ray14 中的照片歸類為 not-covid，並重新進行 COVID-19 模型的訓練。從表 8 中看到當從 Covid-19 資料集中使用 485 張標示為 Covid-19 患者的圖片，以及 Covid-19 資料集中 750 張標示為正常病患的 X 光圖再加上 ChestX-ray14 資料集中的單一病徵 X 光圖 750 張 train-val-test 依照 3:1:1 的比例等比分配圖片並以 Batch-size 為 8 的情況下進行重新訓練，會得到最高的精準度 0.8262，與加入 ChestX-ray14 資料集前的辨識精準度 0.42 相比，效能提升近兩倍。

```

<00011529_000.png> is Normal, predicted as normal.
<00008252_000.png> is Normal, predicted as COVID-19.
<00016509_002.png> is Normal, predicted as COVID-19.
<00020213_025.png> is Normal, predicted as COVID-19.
<00000104_000.png> is Normal, predicted as normal.
<00021006_010.png> is Normal, predicted as COVID-19.
<00019006_002.png> is Normal, predicted as COVID-19.
<00008297_011.png> is Normal, predicted as COVID-19.
<00011481_000.png> is Normal, predicted as normal.
<00017324_000.png> is Normal, predicted as normal.
<00005641_003.png> is Normal, predicted as normal.
mean auroc:0.4213824289405685

```

圖 13、COVID-19 模型測試 ChestX-ray14 之精準度

表 9、COVID-19 模型重新訓練之參數結果比較

Covid-19 資料集中 Covid 圖	Covid-19 資料集中 Normal 圖	ChestX- ray14 中單 病徵圖片	Batch- size	Accuracy	Precision	Recall	F1-score
485	250	250	16	0.630208333	0.706896552	0.431578947	0.535947712

485	750	750	16	0.78645833	0.6	0.32608696	0.42253521
485	750	750	16	0.796875	0.62962963	0.36956522	0.46575342
485	750	750	8	0.82619647	0.73333333	0.45360825	0.56050955
485	450	450	8	0.7807309	0.7012987	0.55670103	0.62068966
485	750	750	4	0.79596977	0.625	0.41237113	0.49689441

● 多回合辨識演算法

基於以上我們重新訓練好的 COVID-19 模型，準確度最高為 0.8262 左右，為再更加精進 COVID-19 模型的精準度，我們希望在測試的過程中找到一組適合協助辨識效果的 Data augmentation 組合，在每個辨識回合中基於前一回合 Data augmentation 後的圖片再新增往上疊加另一種 Data augmentation 方法持續做辨識，最後再綜合各回合的辨識結果，判斷此測試圖片是否為 Covid-19，共分為兩步驟。

(1) 測試各種 Data augmentation 對辨識的影響

A. 針對每單位像素進行常數加減，從表 10 可看到無論函數中所放之參數改變，效果皆不足以影響 COVID-19 模型的辨識效果，且與原先尚未加入 Data augmentation 之測試結果相近，精準度約為 0.8262。

表 10、Add()圖像增強函數對於 COVID-19 模型預測之效果

方法	Accuracy	Precision	Recall	Specific	F1-score
Add(-10)	0.826196	0.73333	0.453608	0.946667	0.56051
Add(0.01)	0.826196	0.73333	0.453608	0.946667	0.56051
Add(0.1)	0.826196	0.73333	0.453608	0.946667	0.56051
Add(10)	0.826196	0.73333	0.453608	0.946667	0.56051
Add(100)	0.826196	0.73333	0.453608	0.946667	0.56051

B. 針對每單位像素進行常數乘法，從表 11 可看到精準度的差異並不大，但在 Multiply(1,1)的情況下得到目前我們最高的精準度 0.8287。

表 11、Multiply()圖像增強函數對於 COVID-19 模型預測之效果

方法	Accuracy	Precision	Recall	Specific	F1-score
Multiply(0.99)	0.82368	0.72131	0.45361	0.94333	0.55696
Multiply(1.01)	0.8262	0.73333	0.45361	0.94667	0.56051
Multiply(1.1)	0.82872	0.7377	0.46392	0.94667	0.56962
Multiply(1.5)	0.82116	0.70313	0.46392	0.93667	0.55901

C. 圖片銳利化，對預測之影響結果如表 12。

表 12、Sharpen()圖像增強函數對於 COVID-19 模型預測之效果

方法 Sharpen()	Accuracy	Precision	Recall	Specific	F1-score
alpha=(0.03), lightness=(0.05)	0.8236	0.721311	0.453608	0.943333	0.556962
alpha=(0.03), lightness=(0.5)	0.826196	0.73333	0.453608	0.946667	0.56051
alpha=(0.03), lightness=(1.1)	0.826196	0.73333	0.453608	0.946667	0.56051
alpha=(0.03), lightness=(1.5)	0.826196	0.73333	0.453608	0.946667	0.56051

D. 改變圖片色彩對比度對預測之影響結果如表 13、14。

表 13、GammaContrast()對於 COVID-19 模型預測之效果(固定第一個參數)

方法 GammaContrast()	Accuracy	Precision	Recall	Specific	F1-score
(0.5, 0.5)	0.81864	0.65432	0.54639	0.90667	0.59551
(0.5, 1.0)	0.82368	0.70149	0.48454	0.93333	0.57317
(0.5, 1.5)	0.8262	0.71212	0.48454	0.93667	0.57669
(0.5, 2.0)	0.82368	0.69014	0.50515	0.92667	0.58333
(0.5, 2.5)	0.8262	0.69444	0.51546	0.92667	0.59172

表 14、GammaContrast()對於 COVID-19 模型預測之效果(固定第二個參數)

方法 GammaContrast()	Accuracy	Precision	Recall	Specific	F1-score
(1.0, 2.5)	0.81108	0.64865	0.49485	0.91333	0.5614
(1.5, 2.5)	0.80856	0.62963	0.52577	0.9	0.57303
(2.0, 2.5)	0.80856	0.62353	0.54639	0.89333	0.58242
(2.5, 2.5)	0.78589	0.56522	0.53608	0.86667	0.55026

E. 高斯糊化函數讓圖片模糊對預測之影響結果如表 15、16。

表 15、GaussianBlur () 對於 COVID-19 模型預測之效果(固定第一個參數)

方法 GaussianBlur()	Accuracy	Precision	Recall	Specific	F1-score
sigma=(0.0, 1.0)	0.8262	0.72581	0.46392	0.94333	0.566038
sigma=(0.0, 3.0)	0.8262	0.69444	0.51546	0.92667	0.59172
sigma=(0.0, 5.0)	0.8262	0.67073	0.56701	0.91	0.61453
sigma=(0.0, 7.0)	0.78841	0.56311	0.59794	0.85	0.58
sigma=(0.0, 9.0)	0.76574	0.51754	0.60825	0.81667	0.55924

表 16、GaussianBlur () 對於 COVID-19 模型預測之效果(固定第二個參數)

方法 GaussianBlur()	Accuracy	Precision	Recall	Specific	F1-score
sigma=(1.0, 1.0)	0.81864	0.68657	0.47423	0.93	0.56098
sigma=(2.0, 1.0)	0.8262	0.7	0.50515	0.93	0.58683
sigma=(3.0, 1.0)	0.82872	0.69333	0.53608	0.92333	0.60465
sigma=(4.0, 1.0)	0.81612	0.63636	0.57732	0.89333	0.60541
sigma=(5.0, 1.0)	0.80353	0.60215	0.57732	0.87667	0.58947

(2) 測試不同 Data augmentation 的疊加組合

我們在設計多回合辨識演算法時，預計進行 10 回合的圖片增強改變，在以上所測試的圖像增強方法中，我們選擇 3 種影像力最高的方法，分別為高斯模糊、Gamma 係數對比、銳利化三種，並在每個方法中找出最有效的兩種參數組合，結果如下。

● 高斯模糊

表 17、A. GaussianBlur(sigma=(1.0))





表 18、B. GaussianBlur(sigma=(2.5))




原始圖片



增強後

● Gamma 係數對比增強

表 19、C. GammaContrast((0.7))



原始圖片



增強後

表 20、D. GammaContrast((1.3))



原始圖片



增強後

- 銳利化

表 21、E. Sharpen(alpha=(0.03), lightness=(0.5))





表 22、F. Sharpen(alpha=(0.03), lightness=(1.1))



以上六種圖像增強方法會分別在多回合演算法中的第一至第六回合個別執行，第七至第九回合則在此三種不同的圖像增強方法中排列出六組合並具有先優順序之差別，再選擇效果最好的三個，比較結果如表 23。

表 23、兩種圖像增強方法疊加之結果比較

方法	Accuracy	Precision	Recall	F1-score
高斯模糊+Gamma 對比	0.823678	0.701493	0.484536	0.93333
Gamma 對比+高斯模糊	0.81864	0.681159	0.484536	0.926667
高斯模糊+銳利化	0.831234	0.727273	0.494845	0.94
銳利化+高斯模糊	0.826196	0.73333	0.453608	0.946667
銳利化+ Gamma 對比	null	null	null	null
Gamma 對比+銳利化	0.821159	0.69697	0.474227	0.933333

表 24、G. 高斯模糊+Gamma 對比




表 25、H. 銳利化+高斯模糊





表 26、I. Gamma 對比+銳利化




在第十回合中，我們將高斯模糊、Gamma 對比、銳利化三中增強方法疊加使用，並將先後順序進行排列組合比較，最後選出一個效果最

好的疊加順序來使用，結果如表 27。

表 27、三種圖像增強方法疊加結果比較













方法	Accuracy	Precision	Recall	F1-score
高斯模糊+ Gamma 對比+ 銳利化	0.813602	0.66667	0.474227	0.92333
高斯模糊+ 銳利化+ Gamma 對比	null	null	null	null
Gamma 對比+ 銳利化+ 高斯模糊	0.821159	0.703125	0.463918	0.936667
Gamma 對比+ 高斯模糊+ 銳利化	0.823678	0.714286	0.463918	0.94
銳利化+ 高斯模糊+ Gamma 對比	null	null	null	null
銳利化+ Gamma 對比+ 高斯模糊	null	null	null	null

表 28、J. Gamma 對比+高斯模糊+銳利化



綜合以上的測試結果，我們在十回合中所使用的圖像增強方法的輸出結果與原圖比較如表 29。

表 29、十回合辨識演算法所使用的方法

原始	A	B	C	D	E
					
原始	F	G	H	I	J
					

● 模型整合

由於我們的目標是針對一張胸腔 X 光圖，首先進行 Covid-19 模型的判斷，將測試資料分類為是 Covid-19 和非 Covid-19 兩大類。COVID-19 模型第一部分的輸出會是一份試算表，如圖 14，裡面包含所有被判斷為 Covid-19 的照片檔名以及被預測的疾病標籤，在此情況下疾病標籤為 Covid-19。

```
Image Index,Predict label
00015969_001.png,Covid-19
covid_386.jpg,Covid-19
covid_6.png,Covid-19
covid_261.jpeg,Covid-19
covid_399.jpg,Covid-19
00009138_016.png,Covid-19
```

圖 14、COVID-19 模型之第一部分結果輸出

COVID-19 第二部分的輸出也是試算表，其內容包含所有被預測為非 Covid-19 的圖片檔名，方便 14 類病徵辨識模型進行預測時的資料取用。並於此時進行 14 類病徵的辨識，在此步驟會再輸出一份試算表，如圖..，其內容與 COVID-19 第一部分的輸出相同，包含所有被判斷為非 Covid-19 的圖片檔名，以及所有 14 類病徵辨識模型所認為此圖片可能存在的病徵標籤，如圖 15 所示。

Image Index	Predict label
00002022_005.png	
00002437_032.png	Infiltration Nodule Pneumonia Consolidation Edema
00002720_011.png	
00003062_002.png	Infiltration Pneumonia Consolidation Edema
00003669_005.png	Cardiomegaly
00004470_006.png	Infiltration Pneumonia Consolidation
00004547_014.png	Atelectasis Effusion Infiltration Mass
00004858_043.png	
00004991_004.png	Cardiomegaly Nodule
00005442_005.png	Cardiomegaly

圖 15、14 類病徵辨識模型針對非 Covid-19 之圖片辨識結果

最後將 COVID-19 模型及 14 類病徵辨識模型的結果合併，會得到完整的測試資料結果，包含所有的測試檔檔名，以及我們的病徵辨識輔助系統所認為可能存在的疾病標籤，輸出結果如圖 16。

Image Index	Predict label
covid_6.png	Covid-19
covid_490.jpeg	Covid-19
covid_483.jpeg	Covid-19
00028874_001.png	Pneumothorax
00028071_003.png	Atelectasis Effusion Infiltration
00027631_007.png	Cardiomegaly
00026478_001.png	Infiltration Edema
00026252_005.png	Effusion Mass
00025811_002.png	Covid-19
00025810_000.png	Emphysema Fibrosis Pleural Thickening

圖 16、綜合結果輸出

● 將輔助系統移植至嵌入式系統上執行

在進行模型移植時，為求在載入模型的速度能增快，我們選擇以 Jetson Nano 作為我們系統移植的平台。深度學習的模型通常結構龐大，需要較大量的運算資源。但在生活中應用大部分都是在嵌入式系統上面執行，嵌入式系統的體積小，運算資源有限，因此在這種條件限制的環境下執行深度學習模型加更加困難。而我們在本專題中也期

望能將我們所訓練出的胸腔 X 光病徵辨識輔助系統移植在嵌入式系統上，增加使用上的便利性。圖 17 為我們正在使用的 Jetson Nano。




圖 17、所使用嵌入式平台 Jetson Nano

當我們實際將系統移植到 Jetson Nano 上不僅在模型的轉換上遇過多次困難，當程式順利能夠執行卻又發現 Jetson Nano 的記憶體相對不足，不管是我們在執行模型載入或是推論階段都曾發生過因為記憶體不足，而被強制停止。

而我們在 Jetson Nano 上實際執行已訓練好的 COVID-19 辨識模型，結果如圖 18 所示，在 Jetson Nano 下運行的精準度為 0.83，每張照片的平均推論時間為 0.13 秒。圖 19 為 Jetson Nano 實際運作之情形。

```
inference-96 normal_1452.jpeg result: [[0.88145405 0.13342877]]
needed time in inference-96: 0.1041111946105957
inference-97 covid_353.png result: [[0.27577937 0.7222175 ]]
needed time in inference-97: 0.10593724250793457
inference-98 covid_171.png result: [[0.76930964 0.24047647]]
needed time in inference-98: 0.10903596878051758
inference-99 covid_322.jpg result: [[0.3474365 0.66880035]]
needed time in inference-99: 0.13952875137329102
average inference time: 0.13060351848602295
ACC : 0.83
```

圖 18、Jetson Nano 載入 COVID-19 模型之辨識結果




圖 19、Jetson Nano 實際運行 COVID-19 模型

將 Jetson Nano 的結果與個人電腦端運行的結果做比較，個人電腦的實際運作結果如圖 20，可發現在推論速度上，Jetson Nano 的速度為個人電腦的兩倍，因此在推論同一張圖的情況下 Jetson Nano 可以省下將近一半的時間。但在準確度上 Jetson Nano 為 0.83，個人電腦則有 0.9，兩者的比較結果如表 30。

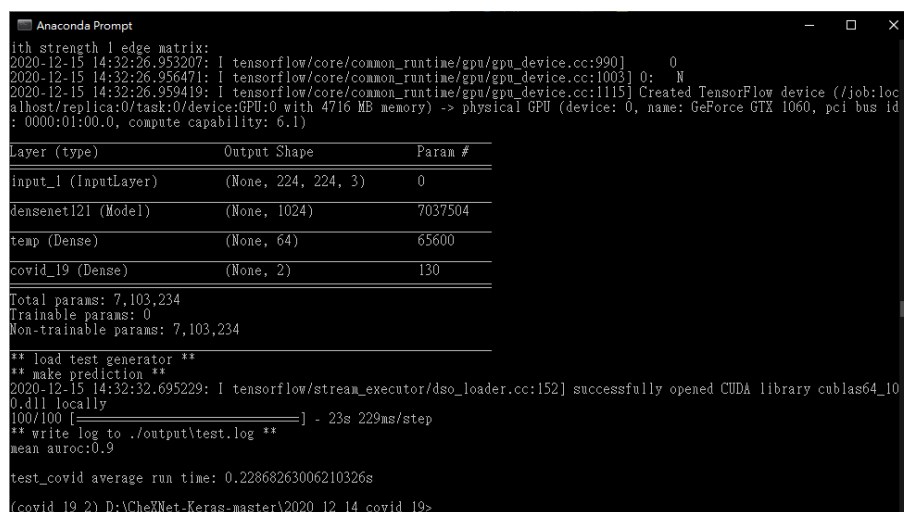


圖 20、個人電腦實際運型 COVID-19 模型

表 30、Jetson Nano 和個人電腦之比較

運作平台	精準度	執行時間
Jetson Nano	0.83	0.11
個人電腦	0.9	0.22

5. 結論

整體來說，我們預計整個模組需包含以下功能，Covid-19 疾病的診斷、14 類疾病的潛在病徵辨識、多回合辨識演算法的使用，經過模型的整合及細節參數的修改，使兩個模型及一個演算法形成一個模組，將我們受測者的胸腔 X 光放入目標資料夾後，送進此模組，透過此模組的處理判斷，取得的結果會是該受測者是否罹患 Covid-19，若不是 Covid-19 則偵測出此受測者可能存在哪些疾病的潛在病徵。

6. 未來發展

專題實驗之 X 光判讀系統主要的目標為提供 X 光初步判斷上的建議，讓醫生能夠獲得第二方的意見，提供醫生即時性的評估，檢測是否有任何病徵，並且預測病患於短時間內是否可能患有其他病徵產生，將此預測結果統整給醫生參考，判斷病患是否有需要提早接受治療，降低延遲發現所導致的病徵惡化。

7. 參考文獻

- [1] Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri, Ronald M. Summers (Dec 14, 2017) 。ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases 。取自 <https://arxiv.org/abs/1705.02315> 。
- [2] ChestX-ray14 資料集。取自 <https://nihcc.app.box.com/v/ChestXray-NIHCC> 。
- [3] brucechou1983 。CheXNet-Keras 。取自 <https://github.com/brucechou1983/CheXNet-Keras/blob/master/models/keras.py> 。
- [4] Tawsifur Rahman, Dr. Muhammad Chowdhury, Amith Khandakar 。COVID-19 Radiography Database 。取自 <https://www.kaggle.com/tawsifurrahman/COVID19-radiography-database> 。
- [5] Wei Hao Khoong 。COVID-19 Xray Dataset (Train & Test Sets) 。取自 <https://www.kaggle.com/khoongweihao/COVID19-xray-dataset-train-test-sets> 。
- [6] Nabeel Sajid 。COVID-19 Patients Lungs X Ray Images 10000 。取自 <https://www.kaggle.com/nabeelsajid917/COVID-19-x-ray-10000-images> 。
- [7] Pranav Raikote 。COVID-19 Image Dataset 。取自 <https://www.kaggle.com/pranavraikote/COVID19-image-dataset> 。
- [8] Dalia Ezzat, Aboul ell Hassanien, Hassan Aboul Ella 。GSA-DenseNet121-COVID-19: a Hybrid Deep Learning Architecture for the Diagnosis of COVID-19 Disease based on Gravitational Search Optimization Algorithm 。取自 <https://arxiv.org/abs/2004.05084> 。

- [9] Alexander Jung ◦ imgaug ◦ 取自 <https://github.com/aleju/imgaug> ◦
- [10]alavaien ◦ imgaug ◦ 取自 <https://gitee.com/alavaien/imgaug> ◦
- [11] Alexander Jung Revision ◦ imgaug ◦ 取自
https://imgaug.readthedocs.io/en/latest/source/overview_of_augmenters.html ◦
- [12] Alexander Jung Revision ◦ imgaug ◦ 取自
https://imgaug.readthedocs.io/en/latest/_modules/imgaug/augmenters/arithmetic.html
◦